

به نام خدا



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر

پروژه درس یادگیری ماشین
بررسی متون علمی با محوریت شبکه های متخاصم مولد

اعضای گروه:

مریم صفوی

مهلا زارع

محمد خورسندی

فهرست مطالب

پیشگفتار	۴
۱- یادگیری انتقالی در شبکه های تخصصی مولد [۱]	۴
۱-۱ بیان مساله	۴
۱-۲ یادگیری انتقالی چیست؟	۵
۱-۳ روش های پیشین برای یادگیری انتقالی GAN ها	۵
۱-۳-۱ تغییر مقیاس و انتقال	۵
۱-۳-۲ آموزش با نظارت مولد	۶
۱-۳-۳ تنظیم دقیق	۶
۱-۴-۳ تبدیل کد پنهان	۶
۱-۴-۴ راهکار های پیشنهادی	۶
۱-۴-۱ انجماد لایه های پایین تشخیص دهنده	۷
۱-۴-۲ تنظیم کنند در شبکه مولد و تشخیص دهنده	۷
۱-۴-۳ تقطیر ویژگی	۷
۲- شبکه های متخاصم مولد مشروط نمونه	۸
۲-۱ بیان مسئله	۸
۲-۲ IC-Gan چیست	۹
۲-۳ مقاسه IC-GAN با تخمین چگالی هسته	۹
۲-۴ مقایسه عملکرد IC-GAN با دیگر رویکردها	۱۰
۲-۵ انتخاب نمونه های ذخیره شده و اندازه محله	۱۰
۳- GAN های جدولی برای توزیع نامنظم	۱۱
۳-۱ بیان مسئله:	۱۱
۳-۲ ساختار GAN جدولی:	۱۱

- ۳-۳ طراحی تابع ضرر ۱۲
- ۴-۳ معیارهای ارزیابی ۱۲
- ۵-۳ نتایج آزمایشی ۱۲
- ۶-۳ ایده‌ی اصلی استنتاجی ۱۲
- ۴- پیاده سازی شبکه تخصصی مولد ۱۴
- ۴-۱ معماری شبکه تشخیص دهنده ۱۴
- ۴-۲ معماری شبکه مولد ۱۵
- ۴-۳ تابع خطا و استراتژی بهینه سازی ۱۶
- ۴-۴ آموزش ۱۷
- ۵-۱ نتایج ۲۰
- مراجع ۲۰

پیشگفتار

در این پروژه به بررسی سه نمونه مقالات اخیر معتبر در زمینه شبکه های تخصصی مولد می پردازیم. در سه بخش ابتدایی سه مقاله

Freeze the Discriminator: a Simple Baseline for Fine-Tuning GANs[[link](#)]

Instance-Conditioned GAN[[link](#)]

Tabular GANs for uneven distribution[[link](#)]

را مورد بررسی قرار می دهیم، در بررسی هر یک از این متون بیان مسئله، ایده اصلی و نتایج بیان شده اند. در بخش انتهایی به پیاده سازی یک شبکه مولد تخصصی ساده می پردازیم و تکنیک های پیاده سازی یک شبکه تخصصی مولد را مورد بررسی قرار می دهیم.

۱- یادگیری انتقالی در شبکه های تخصصی مولد[۱]

۱-۱ بیان مساله

شبکه های تخصصی مولد^۱ یکی از مدل های یادگیری ماشین موفق در زمینه تولید تصاویر ساختگی و شماری از کاربرد های دیگر میباشد. در عین حال عیب این شبکه نیاز به وجود داده بسیار زیاد میباشد. در صورت عدم استفاده از داده کافی احتمال بیش برآزش^۲ مدل وجود دارد. اکثر تلاش هایی که در سال های اخیر در جهت پیشرفت و نوآوری در زمینه شبکه های تخصصی مولد انجام شده نیز مشکل نیاز به داده آموزشی زیاد را داشته اند. در این میان ایده هایی برای یادگیری انتقالی مطرح میشود. البته مقاله مورد بررسی اولین متن عملی نیست که

^۱ Generative adversarial networks (GAN)

^۲ Overfit

این روش را مطرح میکند ولی نویسندگان این مقاله بر این باورند که روش یادگیری انتقالی مطرح شده در این مقاله پیشرفت چشمگیری نسبت به روش های قبلی دارد. روش های یادگیری انتقالی برای شبکه های تخصصی مولد بعضاً با مشکل عدم توانایی در تغییر توزیع مبدا به توزیع مقصد را دارند زیرا انعطاف پذیری زیادی برای تغییر توزیع ندارند.

۱-۲- یادگیری انتقالی^۳ چیست؟

یادگیری انتقالی یکی از تکنیک های یادگیری ماشین است که در آن وزن های آموزش دیده شده برای یک مسئله مشخص، برای آموزش یک مسئله دگر، مشابه با مسئله اولیه استفاده می شوند. این رویکرد از باعث افزایش سرعت یادگیری و کاهش نیاز به داده های زیاد میشود. در یادگیری انتقالی در شبکه های عصبی^۴ معمولاً لایه های پایین یک شبکه عصبی دست نخورده باقی می ماند و لایه های بالا از جایی که قبلاً روی مجموعه داده قلی آموزش دیده اند شروع به آموزش میکنند. البته اگر شبکه دارای لایه های دسته بند باشد بعضاً نیاز است تا با حذف آن لایه ها، شبکه را مطابق با نیاز جدید طراحی کنیم. دلیل نگهداری لایه های پایین این فرضیه است که شبکه های عصبی در لایه های اولیه ویژگی های عام تری را یاد میگیرند که در مسائل دیگر هم مفید واقع می شوند. این دسته از روش ها معمولاً در مواردی کاربرد دارند که داده های آموزشی برای وظایف مشابه فراهم هستند اما حجم داده کافی برای آموزش یک مدل از ابتدا نیست. [۲]

۱-۳- روش های پیشین برای یادگیری انتقالی GAN ها

۱-۳-۱ تغییر مقیاس و انتقال

این روش همه وزن ها را ثابت نگه میدارد و فقط وزن های مربوط به batch normalization را قابل بروزرسانی نگه میدارد. این روش برخلاف روش قبلی انعطاف پذیری پایینی دارد و زمانی که بین توزیع حاکم بر داده های مجموعه داده اول و مجموعه داده دوم اختلاف بیشتری وجود داشته باشد، با این روش قادر به یادگیری توزیع مساله جدید نخواهیم بود.

^۳ Transfer learning

^۴ Neural Network

۱-۳-۲- آموزش با نظارت مولد

کد پنهان^۵ در شبکه های تخصصی مولد به معنی ورودی مولد است. دلیل این نامگذاری این است که مولد می تواند با استفاده از این ورودی که میتواند یک نویز رندوم باشد به یک تصویر برسد، در نتیجه بعد از آموزش، می توانیم استنتاج کنیم که نویز ورودی یا همان کد پنهان یک بازنمایی^۶ از تصویر تولید شد در فضای با بعد کمتر است. چنین بازنمایی هایی در بعد کمتر معمولاً با عباراتی مانند فضای پنهان^۷ یاد میشود زیرا معنی هر کدام از ویژگی های استخراج شده از دید ما پنهان هستند. در این روش که به اختصار GLO نامیده میشود، شبکه مولد را با استفاده از جفت های آموزشی تولید شده توسط شبکه مبدا یک جفت آموزشی برای شبکه مقصد میباشد. تجربه نشان داده است که این روش می تواند مشکل نیازمندی به داده های آموزش زیاد را حل کند اما تصاویر حاصل از این روش اغلب مات هستند. زیرا این روش از تخصص با شبکه تشخیص دهنده بی بهره است.

۱-۳-۳- تنظیم دقیق^۸

در این روش وزن های آموزش دیده شده در مدل مبدا را به مدل مقصد انتقال میدهیم و بدون تغییر منجمد^۹ کردن هیچ کدام از وزن ها اقدام به آموزش میکنیم. البته که این روش در صورتی که داده کافی در اختیار داشته باشیم بهترین عملکرد را دارد زیرا همه لایه ها را با استفاده از توزیع هدف آموزش میدهیم. اما یکی از مشکلاتی که برای حل آن به سراغ یادگیری انتقالی آمده ایم کمبود داده میباشد در نتیجه این روش کارآمد نمیباشد. زیرا در صورتی که داده کافی نداشته باشیم وزن های لایه های اول دانش مفید خود را از دست میدهند.

۱-۳-۴- تبدیل کد پنهان

در این روش از یادگیری انتقالی، وزن های شبکه مولد مبدا را به شبکه مقصد انتقال میدهیم و آموزش آنها را قفل میکنیم. به جای آموزش شبکه مولد یک شبکه استخراج کنند کد پنهان آموزش میدهیم. وظیفه این شبکه بازنمایی کد پنهان به فضای دیگر میباشد. این روش باعث میشود شبکه مولد به داده آموزشی وابسته نشود اما در صورتی قابل استعمال است که توزیع داده های مبدا و توزیع داده های مقصد تا حدودی شباهت داشته باشند.

۱-۴- راهکار های پیشنهادی

^۵ Latent code

^۶ Represenatation

^۷ Latent Space

^۸ Fine-tuning

^۹ Freeze

۱-۴-۱- انجماد لایه های پایین تشخیص دهنده

شبکه تشخیص دهنده مانند یک شبکه دسته‌بند^{۱۰} عمل می‌کند که لایه‌های پایین ویژگی‌هایی از ورودی را به دست آورده و هرچه به سمت لایه‌های بالاتر حرکت می‌کنیم ویژگی‌های استخراج شده انتزاعی‌تر می‌شوند ولی قابلیت استفاده از این ویژگی‌ها برای مسئله‌های دیگر کاهش می‌یابد. به همین دلیل روش پیشنهادی در این مقاله لایه‌های پایین تشخیص دهنده را منجمد می‌کند و لایه‌های بالا را قابل آموزش باقی می‌گذارد. این راهکار ساده و در عین حال موثر freezD نامیده می‌شود.

۱-۴-۲- تنظیم کنند در شبکه مولد و تشخیص دهنده

مشکل اصلی در یادگیری شبکه‌های تخصصی مولد، کمبود داده است. کمبود داده برای یک مسئله پیچیده باعث بیش برآزش می‌شود. یکی از راه‌هایی که توسط نویسندگان مقاله بررسی شده استفاده از تنظیم کننده در هر دو شبکه مولد مقصد و تشخیص دهنده مقصد می‌باشد (به طور دقیق‌تر افزودن نرم ۲ وزن‌ها به تابع هزینه^{۱۱}). این روش باعث می‌شود وزن‌های شبکه‌های مقصد با گام‌های بلند و به طور ناگهانی از شبکه مبدا دور نشوند. هرچند این روش نتایج مطلوبی را به همراه ندارد. یکی از مشکلات این روش این است که اگر لایه‌هایی از شبکه‌ها را منجمد کنیم به این معنی است که به آنها وزن بی‌نهایت داده‌ایم و به بقیه لایه‌ها وزن صفر داده‌ایم زیرا تنها وزن لایه‌هایی که منجمد نشده‌اند در تنظیم کننده ظاهر می‌شوند و این باعث کوچک‌تر شدن وزن آنها می‌شود. راه حل پیشنهادی این مقاله استفاده از ضرایب مختلف برای منظم سازی لایه‌ها می‌باشد.

۱-۴-۳- تقطیر ویژگی

تقطیر ویژگی یک تکنیک در حوزه یادگیری ماشین است که برای انتقال دانش از یک مدل به مدل دیگر استفاده می‌شود. در این روش، دانشی که یک مدل پیش‌آموزش‌دیده (معمولاً یک مدل پیچیده و بزرگتر) در طی یادگیری از داده‌ها به دست آورده است، به یک مدل هدف (که ممکن است کوچکتر یا ساده‌تر باشد) منتقل می‌شود. در این حالت به مدل مبدا معلم و به مدل مقصد دانش‌آموز گفته می‌شود. شبکه دانش‌آموز علاوه بر داده‌های مربوط به مسئله خود، با استفاده جفت‌های آموزشی تولید شده توسط معلم نیز آموزش می‌بیند. تولید مجموعه داده آموزشی توسط معلم به این صورت می‌باشد که هر ورودی به شبکه معلم و خروجی متناظر، یک جفت آموزشی را تشکیل می‌دهد. این انتقال دانش شامل نهایی‌ترین پیش‌بینی و یا بازنمایی‌های میانی است. انتقال دانش به لایه‌های میانی شبکه، به عنوان تقطیر ویژگی یاد می‌شود. تابع هزینه به گونه‌ای تعریف می‌شود که اختلاف بین

^{۱۰} Classification

^{۱۱} Cost function

خروجی استاد و دانش‌آموز را اندازه‌گیری می‌کند. دانش‌آموز یادمیگیرد تا این اختلاف را کمینه کند و در نتیجه دانش استاد را با بازتولید کند. از دیگر روش‌های بررسی شده برای یادگیری انتقالی در شبکه‌های تخصصی مولد، می‌توان به تقطیر ویژگی اشاره کرد. در نتیجه انجام آزمایش، به این نتیجه رسیده شده که تقطیر ویژگی نتایج مقایسه‌پذیری با دارد، اما دو برابر محاسبات نیاز دارد. به عبارت دیگر، این روش در مقایسه با FreezeD، از لحاظ محاسباتی، پیچیدگی بالاتری دارد. در حالی که استفاده از تکنیک‌های پیشرفته‌تر در تقطیر ویژگی ممکن است نتایج بهتری را به همراه داشته باشد.

۲- شبکه‌های متخاصم مولد مشروط نمونه^{۱۲}

۲-۱ - بیان مسئله

شبکه‌های متخاصم مولد (GANs) می‌توانند تصاویر واقعی نزدیک به عکس را در حوزه‌های حساسی مانند چهره انسان تولید کنند. با این حال، مدل‌سازی توزیع‌های پیچیده مجموعه داده‌هایی مانند ImageNet و COCO- Stuff همچنان در تنظیمات بدون قید و شرط چالش برانگیز است. در مقاله بررسی شده، از تکنیک‌های تخمین

^{۱۲} Instance-Conditioned GAN

چگالی هسته^{۱۳} الهام گرفته شده و یک رویکرد ناپارامتریک برای مدل سازی توزیع های مجموعه داده های پیچیده معرفی شده است. منیفولد داده را به مخلوطی از همسایگی های همپوشانی که توسط یک نقطه داده و نزدیک ترین همسایگان آن توصیف شده است، تقسیم می کند و مدلی به نام GAN شرطی شده نمونه (IC-GAN) معرفی می کند که توزیع اطراف هر نقطه داده را یاد می گیرد.

۲-۲- IC-Gan چیست

رویکرد جدید به نام GAN شرطی نمونه (IC-GAN) معرفی شده که چارچوب GAN را برای مدل سازی ترکیبی از تراکم داده های محلی گسترش می دهد. به طور دقیق تر، IC-GAN با ارائه نمایشی از نمونه به عنوان ورودی اضافی برای تولیدکننده^{۱۴} و تمایزکننده^{۱۵}، و با استفاده از همسایه های یک نقطه داده، مدل سازی توزیع همسایگی یک نقطه داده را که به عنوان نمونه نیز نامیده می شود، می آموزد. با انتخاب یک محله به اندازه کافی بزرگ در اطراف نمونه شرطی، از دام تقسیم بیش از حد داده ها به خوشه های کوچک جلوگیری می کنیم. با توجه به ماهیت همپوشانی این خوشه ها، افزایش تعداد پارتیشن ها به قیمت داشتن نمونه های کمتر در هر یک از آنها تمام نمی شود. علاوه بر این، برخلاف زمانی که روی شاخص های خوشه ای گسسته شرطی سازی می شود، شرطی شدن بر روی نمایش های نمونه به طور طبیعی مولد را به تولید نمونه های مشابه هدایت می کند. جالب است که پس از آموزش، IC-GAN می تواند برای انتقال بی دردسر به مجموعه داده های دیگر که در طول آموزش دیده نمی شوند، به سادگی با تعویض نمونه های شرطی در زمان استنتاج استفاده شود. ایده کلیدی IC-GAN مدل سازی توزیع یک مجموعه داده پیچیده با استفاده از خوشه های همپوشانی ریز دانه در منیفولد داده است که در آن هر خوشه با یک نقطه داده (x_i) که به عنوان نمونه و نزدیکترین مجموعه همسایگان آن (A_i) در یک فضای ویژگی توصیف می شود. هدف مدل سازی توزیع داده های اساسی $p(x)$ به عنوان مخلوطی از توزیع های شرطی $p(x|hi)$ در اطراف هر یک از M بردارهای ویژگی نمونه (hi) در مجموعه داده است.

$$p(x) = \frac{1}{M} \sum_i p(x|hi)$$

۲-۳- مقایسه IC-GAN با تخمین چگالی هسته

^{۱۳} Kernel density estimation (KDE)

^{۱۴} Generator

^{۱۵} Discriminator

IC-GAN شباهت هایی با تخمین چگالی هسته (KDE) دارد، یک تخمینگر چگالی غیر پارامتری به شکل مخلوطی از هسته های پارامتری که چگالی را در اطراف هر نقطه داده آموزشی مدل می کند. مشابه KDE، IC-GAN را می توان به عنوان یک تخمینگر چگالی مخلوط مشاهده کرد که در آن هر جزء با شرطی کردن یک نمونه آموزشی به دست می آید. با این حال در این رویکرد، برخلاف KDE، احتمال داده ها به صراحت مدل سازی نمی شود، بلکه یک رویکرد خصمانه در پیش گرفته می شود که در آن چگالی محلی به طور ضمنی با یک شبکه عصبی مدل سازی می شود که نمونه شرطی سازی و همچنین بردار نویز را به عنوان ورودی می گیرد. بنابراین، هسته IC-GAN دیگر به نقطه داده ای که در آن شرط می کنیم مستقل نیست و به جای پارامتر پهنای باند هسته، با انتخاب اندازه همسایگی نمونه ای که نمونه های واقعی را از آن نمونه برداری می کنیم، صافی^{۱۶} را کنترل می کنیم.

۲-۴- مقایسه عملکرد IC-GAN با دیگر رویکردها

IC-GAN، یک مدل مولد آموزش دیده در ImageNet، قابلیت های انتقال قابل توجهی را در هنگام استفاده برای تولید تصاویر از نمونه های COCO-Stuff نشان می دهد. مدل آموزش داده شده در ImageNet از همان مدل آموزش داده شده در COCO-Stuff بهتر عمل می کند و کارایی ویژگی های از پیش آموزش دیده ImageNet را برجسته می کند. این مدل همچنین از سایر مدل هایی که در حاشیه نویسی برچسب گذاری شده شرط می کنند، بهتر عمل می کند. علاوه بر این، IC-GAN می تواند معنا و سبک تصاویر را هنگام انتقال به مجموعه داده های دیگر مانند Cityscapes، MetFaces و PACS، هر چند با کیفیت کمی پایین تر حفظ کند، در یک تنظیم شرطی کلاس، IC-GAN از BigGAN از نظر FID و IS بهتر عمل می کند و می تواند معنای تصاویر تولید شده را با اصلاح ویژگی های نمونه و تعویض شرطی سازی کلاس یا برعکس کنترل کند. در آزمایش ها بر روی توزیع long-tailed از مجموعه داده ImageNet-LT، (آی سی گن) از نظر FID و IS برای مدل سازی این توزیع بهتر از BigGAN عمل می کند.

IC-GAN از نظر امتیازات FID و IS در رزولوشن های ۶۴*۶۴ و ۱۲۸*۱۲۸ از رویکردهای قبلی بهتر عمل می کند. همچنین با وضوح ۲۵۶*۲۵۶ از مدل مبتنی بر انتشار پیشی گرفته است. IC-GAN تصاویری با کیفیت بالا تولید می کند که تفاوت قابل توجهی با نمونه های آموزشی دارد. در مجموعه داده COCO-Stuff، IC-GAN به امتیازات رقابتی FID در مقایسه با مدل های پیشرفته تولید صحنه پیچیده دست می یابد. به دلیل استفاده از چندین نمونه همسایه واقعی در طول آموزش، تنوع بیشتری نسبت به مدل های دیگر نشان می دهد.

۲-۵- انتخاب نمونه های ذخیره شده و اندازه محله

^{۱۶} smoothing

- نمونه‌گیری یکنواخت^{۱۷} (تصادفی)
- روش K_mean (خوشه‌بندی)

انتخاب تصادفی به طور مداوم توسط k-means بهتر عمل می‌کند. انتخاب تنها ۱۰۰۰ نمونه با k-means منجر به FID بهتری نسبت به انتخاب تصادفی ۵۰۰۰ نمونه می‌شود. علاوه بر این، ذخیره بیش از ۱۰۰۰ نمونه انتخاب شده با k-means منجر به بهبود قابل توجهی در FID نمی‌شود. افزایش تعداد نمونه‌های ذخیره شده منجر به دقت کمی بدتر (کیفیت تصویر) اما به ویژه پوشش بهتر می‌شود. به طور شهودی، این نشان می‌دهد که با افزایش تعداد نمونه‌های ذخیره‌شده، می‌توانیم چگالی داده‌ها را بهتر بازبانی کنیم.

۳- GAN های جدولی برای توزیع نامنظم

۳-۱- بیان مسئله:

نویسندگان با برجسته کردن چالشی که توزیع نامتوازن مجموعه‌های داده جدولی ایجاد می‌کند، شروع به نوشتن می‌کنند. در بسیاری از سناریوهای واقعی، مانند تشخیص‌های پزشکی یا شناسایی کلاهبرداری، برخی کلاس‌ها یا دسته‌ها نسبت به دیگران کمیاب هستند. این نامتوازنی می‌تواند منجر به مدل‌های تبعیض‌آمیزی شود که در کلاس‌های کمیاب عملکرد نامناسبی داشته باشند. GAN های سنتی ممکن است در به دست آوردن توزیع پیچیده‌ای از این داده‌ها و اغلب نمونه‌های مصنوعی تولید می‌کنند دچار مشکل شود که نتوانند به درستی کلاس‌های کمیاب را نمایش دهند.

۳-۲- ساختار GAN جدولی:

ساختاری که پیشنهاد شده است به طور خاص برای داده‌های جدولی طراحی شده است. برخلاف داده‌های تصویری که روابط فضایی اساسی هستند، داده‌های جدولی از ردیف‌ها و ستون‌ها با ارزش‌های گسسته یا پیوسته تشکیل شده‌اند. این ساختار شامل تکنیک‌هایی مانند تبدیل‌های مبتنی بر ویژگی است که به طور تطبیقی هر ویژگی را نرمال‌سازی می‌کند تا در طول آموزش همگرایی را بهبود بخشد. به علاوه، تولید شرطی کلاس به کلاس معرفی شده است تا اطمینان حاصل شود که مولد بر روی تولید نمونه‌ها برای کلاس‌های کم نمایان تمرکز کند و در نتیجه نامتوازنی موجود در مجموعه داده را برطرف کند.

^{۱۷} Unioform sampeling

۳-۳ طراحی تابع ضرر:

طراحی تابع ضرر موثر برای هدایت آموزش مدل GAN بسیار حیاتی است. در این مقاله، نویسندگان یک تابع ضرر جدید پیشنهاد می‌دهند که ترکیبی از تابع‌های ضرر GAN سنتی با اصطلاحات اضافی است که از انحرافات از توزیع هدف، به ویژه برای کلاس‌های کمیاب، جلوگیری می‌کند. با ادغام وزن‌های معین کلاس یا استراتژی‌های نمونه‌برداری، تابع ضرر تولید کننده را تشویق می‌کند تا نمونه‌هایی تولید کند که به دقت تمام مجموعه داده را نشان دهند، با تمرکز بر بهبود نمایش نمونه‌های کمیاب.

۳-۴- معیارهای ارزیابی:

ارزیابی عملکرد یک مدل تولیدی نیاز به در نظر گرفتن دقیق معیارهای مرتبط دارد. به علاوه از معیارهای سنتی ارزیابی GAN مانند امتیاز شروع یا فاصله امتیاز شروع (FID)، این مقاله معیارهای دقت، بازیابی و امتیاز F_1 کلاس-به-کلاس را به عنوان معیارهایی منطبق بر داده‌های جدولی معرفی می‌کند. این معیارها به ما درکی از اینکه نمونه‌های تولید شده به چه اندازه توزیع هر کلاس در مجموعه داده می‌پیوندند، ارائه می‌دهند که به ارزیابی جزئی‌تری از عملکرد مدل کمک می‌کند.

۳-۵- نتایج آزمایشی:

اثربخشی رویکرد Tabular GAN پیشنهادی از طریق آزمایش‌های گسترده بر روی مجموعه داده‌های واقعی با توزیع‌های نامتوازن نشان داده شده است. آزمایش‌ها عملکرد Tabular GAN را با مدل‌های مقایسه‌ای و GAN‌های سنتی مقایسه می‌کنند، با برجسته کردن بهبودهای در تولید داده‌های مصنوعی که بهتر بازتاب توزیع زیرین را دارند، به ویژه برای کلاس‌های کم یا موارد نادر. نتایج ویژگی‌های بالقوه این رویکرد پیشنهادی را در برطرف کردن چالش‌های داده‌های جدولی نامتوازن نشان می‌دهد و راه را برای تحقیقات آینده در این زمینه هموار می‌کند.

این مقاله با مورد به مورد بررسی هر بخش، یک چارچوب جامع برای بهره‌گیری از GAN‌ها برای تولید داده‌های جدولی مصنوعی ارائه می‌دهد، با تمرکز خاص بر روی حل مسائل توزیع نامتوازن داده.

۳-۶- ایده‌ی اصلی استنتاجی:

مقاله "GAN های جدولی برای توزیع نامنظم" به عمق حوزه تولید داده‌های مصنوعی ویژه دیتاست‌های جدولی که به توزیع‌های نامنظم مشخص شده‌اند، می‌پردازد. این یک مسئله حیاتی در حوزه‌های مختلفی از جمله بهداشت، مالی، و بازاریابی است، جایی که داده‌ها اغلب توزیع‌های پیچیده و انحرافی را از خود نشان می‌دهند، که باعث می‌شود تولید نمونه‌های مصنوعی نمایانگر برآوردنی از داده‌ها چالش برانگیز باشد.

شبکه‌های مخرب تولیدی سنتی (GANs) موفقیت‌های قابل توجهی را در تولید داده‌های مصنوعی که شباهت زیادی به توزیع مبنای داده‌های آموزشی دارند، نشان داده‌اند. اما زمانی که توزیع داده نامتعادل است، اغلب دچار مشکلات می‌شوند که منجر به تولید نمونه‌هایی می‌شود که جزئیات و نوعیت‌های مجموعه داده اصلی را دربرنمی‌گیرند. این محدودیت موانع مهمی را در وظایفی مانند افزایش داده، حفظ حریم خصوصی، و تولید مجموعه‌های داده مصنوعی متنوع برای آموزش مدل‌های یادگیری ماشین ایجاد می‌کند.

برای مقابله با این چالش، نویسندگان GAN های جدولی را ارائه می‌دهند، یک رویکرد نوآورانه که به طور خاص برای داده‌های جدولی با توزیع‌های نامتعادل طراحی شده است. نوآوری اصلی در یک فرآیند آموزش دو مرحله‌ای قرار دارد که برای حل پیچیدگی‌های توزیع‌های نامتعادل داده و به‌دست آوردن ساختار مخفی مجموعه داده به‌طور مؤثر طراحی شده است.

در مرحله اول، GAN های جدولی از یک تابع از دست رفتگی جدید به نام معیار استقلال واسرشتاین (WIC) استفاده می‌کنند. این تابع از دست رفتگی برای به‌دست آوردن وابستگی‌ها و ارتباطات پیچیده موجود در داده‌ها طراحی شده است، به‌ویژه در حالت‌هایی که توابع از دست رفتگی سنتی ممکن است به‌طور کافی توزیع داده را نشان ندهند. با بهینه‌سازی از دست رفتگی WIC، هدف GAN های جدولی این است که یک نمایش مخفی از داده را یاد بگیرند که ساختار مخفی آن را با وفاداری حفظ کند، حتی در حضور توزیع‌های نامتعادل.

مرحله دوم آموزش شامل بهره‌برداری از یک چارچوب GAN شرطی برای تولید نمونه‌های مصنوعی با شرایط ویژه یا کلاس‌ها است. این رویکرد تولید شرطی امکان می‌دهد که GAN های جدولی بتوانند داده‌های مصنوعی را با حفظ ویژگی‌ها و خصوصیت‌های مجموعه داده اصلی تولید کنند. با شرط بندی فرآیند تولید بر ویژگی‌ها یا کلاس‌های مرتبط، GAN های جدولی اطمینان حاصل می‌کنند که نمونه‌های تولید شده به نزدیکی موارد داده واقعی شباهت داشته باشند، بدین ترتیب کیفیت و تنوع مجموعه داده مصنوعی را ارتقا می‌دهند.

کارایی GAN های جدولی از طریق آزمایشات گسترده‌ای که بر روی دیتاست‌های واقعی با توزیع‌های نامتعادل انجام شده است نشان داده می‌شود. این آزمایشات برتری GAN های جدولی را نسبت به روش‌های موجود در مواردی از نظر کیفیت نمونه، تنوع، و وفاداری به توزیع داده اصلی نشان می‌دهند. به‌طور اضافی، ارزیابی‌های کیفی و کمی نشان می‌دهند که GAN های جدولی در دامنه‌ها و انواع داده‌های مختلف، سختی و چند کاربردی را دارند.

در نتیجه، GAN های جدولی یک راهکار امیدوار کننده برای تولید داده‌های جدولی مصنوعی در شرایطی که توزیع نامتعادل است، ارائه می‌دهند. با بهره‌گیری از یک فرآیند آموزش دو مرحله‌ای و توابع از دست رفتگی

نوآورانه، GAN های جدولی به چالش های مرتبط با توزیع های نامتعادل داده پاسخ می دهند، راه را برای کاربردهای افزایش داده، حفظ حریم خصوصی، و تولید داده های مصنوعی برای وظایف یادگیری ماشین می گشایند.

۴- پیاده سازی شبکه تخصصی مولد

در این قسمت پیاده سازی شبکه تخصصی مولد مورد بررسی قرار میگیرد. کد پیاده سازی شده این شبکه تخصصی مولد در این [مخزن گیت هاب](#) موجود میباشد.

۴-۱- معماری شبکه تشخیص دهنده

برای پیاده سازی یک شبکه تخصصی مولد معماری شبکه تشخیص دهنده را به صورت زیر طراحی کردیم. تابع فعال سازی leaky relu انتخابی معمول برای شبکه های تشخیص دهنده میباشد. استفاده از تابع فعال سازی Leaky ReLU برای حل مشکل dying ReLU میباشد. این مشکل زمانی رخ میدهد که نورون ها در وضعیتی

گیر کرده‌اند که واحدهای ReLU همیشه خروجی ۰ را برای همه ورودی‌ها تولید می‌کنند. در این حالت، مشتقات نمیتوانند به لایه‌های پایین شبکه راه پیدا کنند و مشتق صفر به لایه‌های قبل منتقل میشود. جلوگیری از این مسئله برای GAN ها به طور بخصوص حائز اهمیت است. همچنین خروجی این شبکه تابع سیگموید است تا بتواند خروجی باینری را توصیف کند. ورودی این شبکه پیکسل‌های یک تصویر به شکل تخت شده میباشند.

```
1 class Discriminator(nn.Module):
2     def __init__(self):
3         super(Discriminator, self).__init__()
4
5         self.model = nn.Sequential(
6             nn.Linear(784, 256),
7             nn.LeakyReLU(0.2),
8             nn.Linear(256, 1),
9             nn.Sigmoid()
10        )
11
12    def forward(self, x):
13        return self.model(x)
```

۲-۴- معماری شبکه مولد

همچنین معماری تولید کننده در تصویر زیر مشخص است. ورودی این شبکه یک نویز رندم می باشد که در واقع همان کد پنهان است. خروجی این شبکه یک تصویر تخت شده می باشد که به تعداد پیکسل های تصویر عنصر دارد. برای تابع فعالسازی لایه خروجی تانژانت هیپربولیک استفاده شده که خروجی بین -۱ و ۱ تولید میکند. از آنجا که ما در طی فرایند نرمال سازی پیکسل های تصاویر اصلی را به مقیاس -۱ و ۱ بردیم، این تابع فعالسازی باعث می شود تفاوت مقیاس بین پیکسل های تصاویر اصلی و تصاویر جعلی وجود نداشته باشد.

```

1 class Generator(nn.Module):
2     def __init__(self):
3         super(Generator, self).__init__()
4         self.model = nn.Sequential(
5             nn.Linear(100, 256),
6             nn.ReLU(),
7             nn.Linear(256, 784),
8             nn.Tanh()
9         )
10
11     def forward(self, z):
12         return self.model(z)
13

```


۴-۳- تابع خطا و استراتژی بهینه سازی

برای آموزش از تابع خطای BCE برای هر دو شبکه استفاده می‌کنیم. زیرا شبکه تشخیص دهنده یک دسته‌بند دو کلاسه می‌باشد که کلاس‌های آن شامل اصلی و جعلی می‌شود. برای شبکه مولد نیز از تابع خطای BCE استفاده می‌کنیم. بدین صورت که مقدار y را به طور ثابت عدد ۱ ارسال می‌کنیم حالت ایده‌آل برای شبکه مولد این است که شبکه تشخیص دهنده نتواند هیچ کدام از تصاویر تولید شده را به عنوان تصویر جعلی تشخیص دهد. خروجی شبکه تشخیص دهنده را به عنوان آرگومان دیگر به این تابع خطا ارسال می‌کنیم. اگر شبکه تشخیص دهنده عکس‌های تولید شده توسط شبکه مولد را به درستی تشخیص دهد، عدد صفر را به عنوان خروجی باز می‌گرداند. برای بهینه سازی از روش adaptive momentum استفاده شده است.


```
1 generator = Generator()  
2 discriminator = Discriminator()  
3  
4 loss_func = nn.BCELoss()  
5 optimizer_G = optim.Adam(generator.parameters(), lr=learning_rate)  
6 optimizer_D = optim.Adam(discriminator.parameters(), lr=learning_rate)  
7
```

۴-۴- آموزش

نحوه آموزش شبکه های متخاصم در تصویر زیر مشهود است. در مرحله اول به تعداد batch نویز رندوم تولید میشود سپس به ازای هر نویز یک تصویر جعلی تولید میشود. در مرحله بعد می بایستی گرادیان هایی که در دور قبل محاسبه شده اند را پاک کرده و آماده محاسبه گرادیان های جدید شویم. در صورت عدم انجام این کار گرادیان ها به صورت تجمعی ذخیره خواهند شد و در نتیجه مقدار گرادیان اشتباه خواهد بود. خطا برای شبکه تشخیص دهنده برابر مجموع خطا روی تصاویر جعلی و اصلی می باشد. همچنین خطای شبکه مولد با تعداد تصاویری که در واقع جعلی بوده اند و توسط شبکه تشخیص دهنده به درستی تشخیص داده شده اند متناسب است.




```

1  for epoch in range(epochs):
2      for i, (real_images, _) in enumerate(dataloader):
3          cur_bs = real_images.shape[0]
4          # Generate fake picture
5          z = torch.randn(cur_bs, 100)
6          fake_images = generator(z)
7
8          # Train discriminator
9          optimizer_D.zero_grad()
10
11         ons_vec = torch.ones(cur_bs, 1)
12         zeros_vec = torch.zeros(cur_bs, 1)
13
14         real_outputs = discriminator(real_images.view(cur_bs, -1))
15         fake_outputs = discriminator(fake_images.detach().view(cur_bs, -1))
16
17         loss_real = loss_func(real_outputs, ons_vec)
18         loss_fake = loss_func(fake_outputs, zeros_vec)
19         loss_discriminator = loss_real + loss_fake
20
21         loss_discriminator.backward()
22         optimizer_D.step()
23
24         # Train Generator
25         optimizer_G.zero_grad()
26
27         generated_outputs = discriminator(fake_images.view(cur_bs, -1))
28         loss_generator = loss_func(generated_outputs, ons_vec)
29
30         loss_generator.backward()
31         optimizer_G.step()
32

```

نمونه تصاویر تولیدی توسط gan آموزش داده شده بر روی اعداد ۱ و ۲ از تصاویر مجموعه داده ارقام دست نویس [۳]



۵-۱- نتایج

برای بررسی تاثیر روش freezeD بر GAN های ساده (بدون شرط) از شبکه والدی که روی مجموعه داده FFHQ (مجموعه داده چهره انسان) آموزش داده شده، استفاده میشود. سپس آن را بر مجموعه داده Animal Face و Anime Face تنظیم دقیق می کنند. رویکرد FreezeD با تنظیم دقیق معمولی (بدون انجماد لایه ها) با استفاده از امتیازهای FID مقایسه می شود، که نشان می دهد که عملکرد آن بهبود یافته است. نویسندگان همچنین FreezeD را با چندین روش قبلی مانند GLO, scale/shift, MineGAN, L²-SP و feature distillation مقایسه می کنند. نتایج نشان می دهند که روش FreezeD از نظر تنوع و کیفیت تصویر بهتر عمل می کند. برای GAN های شرطی، نویسندگان از معماری SNGAN-projection استفاده می کنند و آن را روی مجموعه داده ImageNet آموزش می دهند و سپس آن را روی مجموعه داده هایی مانند CUB-۲۰۰ و ۲۰۱۱ Caltech-۲۵۶ تنظیم دقیق می کنند. سپس روش FreezeD با روش تنظیم دقیق معمولی (بدون انجماد لایه ها) مقایسه می شود. مقایسه نتایج با استفاده از معیار FID نشان می دهد که FreezeD به طور کلی عملکرد را بهبود می بخشد.

مراجع

- [۱] S. Mo, M. Cho, and J. Shin, "Freeze the Discriminator: a Simple Baseline for Fine-Tuning GANs." arXiv, Feb. ۲۸, ۲۰۲۰. doi: ۱۰,۴۸۵۵۰/arXiv.۲۰۰۲,۱۰۹۶۴.
- [۲] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, "How transferable are features in deep neural networks?" arXiv, Nov. ۰۶, ۲۰۱۴. doi: ۱۰,۴۸۵۵۰/arXiv.۱۴۱۱,۱۷۹۲.
- [۳] "Papers with Code - MNIST Dataset." Accessed: Jan. ۳۱, ۲۰۲۴. [Online]. Available: <https://paperswithcode.com/dataset/mnist>